LAPORAN ANALISIS BIOINFORMATIKA: EKSPRESI GEN PADA KARSINOMA SEL SKUAMOSA KEPALA DAN LEHER (HNSCC)

Oleh: Jeanette Kallista Lim Dataset: GSE6631

Karsinoma Sel Skuamosa Kepala dan Leher (Head and Neck Squamous Cell Carcinoma atau HNSCC) merupakan salah satu jenis keganasan yang memiliki tingkat morbiditas tinggi karena sifatnya yang invasif. Penyakit ini berkembang melalui akumulasi perubahan genetik yang menyebabkan disregulasi jalur sinyal seluler. Penggunaan data transkriptomik melalui teknologi microarray memungkinkan peneliti untuk memetakan perbedaan ekspresi gen secara menyeluruh antara jaringan kanker dan jaringan mukosa normal. Tujuan dari analisis ini adalah untuk mengidentifikasi gen yang diekspresikan secara diferensial (Differentially Expressed Genes atau DEGs) guna memahami mekanisme molekuler di balik progresi tumor pada HNSCC dan mengevaluasi kualitas data yang digunakan.

2. Metode

2.1 Dataset dan Sumber Data

Dataset yang digunakan dalam analisis ini adalah GSE6631 yang diakses dari database publik Gene Expression Omnibus (GEO) NCBI. Dataset ini menggunakan platform Affymetrix HG-U95Av2 (GPL8300). Fokus analisis dilakukan pada sub-set data yang terdiri dari 15 sampel biologis untuk membandingkan kondisi normal dan patologis.

2.2 Pembagian Grup

Sampel dikelompokkan menjadi dua grup utama berdasarkan kondisi klinis jaringan:

- Grup Kontrol (Normal): Terdiri dari 8 sampel mukosa normal (GSM153813, GSM153815, GSM153817, GSM153819, GSM153821, GSM153823, GSM153825, GSM153827).
- Grup Kanker (HNSCC): Terdiri dari 7 sampel jaringan kanker (GSM153814, GSM153816, GSM153818, GSM153820, GSM153822, GSM153824, GSM153826).

2.3 Parameter GEO2R dan Statistik

Analisis dilakukan menggunakan instrumen GEO2R dengan parameter sebagai berikut:

- Uji Statistik: limma (Linear Models for Microarray Data) untuk stabilitas varians.
- Koreksi Multiple Testing: Benjamini–Hochberg False Discovery Rate (FDR).
- Kriteria Signifikan: Adjusted p-value (Padj) < 0.05.
- Visualisasi: Reduksi dimensi menggunakan UMAP (Uniform Manifold Approximation and Projection) dan plot vulkano (Volcano Plot) untuk identifikasi DEGs.

3. Hasil dan Interpretasi

3.1 Kontrol Kualitas dan Normalisasi

Berdasarkan Density Plot dan Boxplot, distribusi intensitas ekspresi gen di seluruh 15 sampel menunjukkan pola yang sangat seragam dan simetris. Hal ini mengindikasikan bahwa proses normalisasi telah berhasil dilakukan, sehingga perbedaan ekspresi yang muncul di tahap selanjutnya dapat diatribusikan pada perbedaan biologis (Kanker vs Normal) dan bukan karena artefak teknis. Data ini dikategorikan sebagai data yang sangat bagus secara teknikal.

3.2 Analisis Klastering (UMAP)

Hasil visualisasi UMAP menunjukkan pemisahan yang jelas antara kelompok Kontrol (hijau) dan kelompok Kanker (ungu). Terbentuknya dua klaster yang terpisah secara diskrit ini membuktikan adanya perbedaan profil transkriptomik yang kuat. Meskipun terdapat sedikit

kedekatan posisi pada beberapa sampel, secara keseluruhan "tanda tangan molekuler" kanker sangat berbeda dari mukosa normal.

3.3 Analisis Ekspresi Diferensial (DEGs)

Melalui Volcano Plot dan Diagram Venn, teridentifikasi sebanyak 88 gen signifikan yang memenuhi kriteria Padj < 0.05.

- Gen Up-regulated: Gen yang berada di sisi kanan plot (merah) secara teoretis mencakup onkogen dan enzim pembedah jaringan seperti Matrix Metalloproteinases (MMPs).
- Gen Down-regulated: Gen di sisi kiri plot (biru) kemungkinan merupakan tumor supresor yang ekspresinya hilang selama proses keganasan.
  Distribusi P-value pada histogram menunjukkan puncak yang signifikan pada rentang 0.00 - 0.05, yang memperkuat validitas statistik dari 88 gen tersebut.

3.4 Interpretasi Biologis (GO & Pathway)

Secara teoretis, gen-gen yang teridentifikasi berpartisipasi dalam jalur PI3K-Akt signaling, Cell cycle, dan Extracellular matrix receptor interaction. Hal ini menjelaskan mengapa sel kanker HNSCC memiliki kemampuan proliferasi yang tidak terkendali dan kemampuan untuk menginvasi jaringan sekitar melalui perombakan matriks ekstraseluler.

4. Kesimpulan

Berdasarkan hasil analisis, dapat disimpulkan bahwa dataset GSE6631 memiliki kualitas yang sangat tinggi dan layak digunakan untuk studi biomarker. Analisis berhasil menjawab tujuan penelitian dengan memetakan 88 gen kunci yang berekspresi secara diferensial antara kondisi normal dan HNSCC. Pemisahan sampel pada UMAP dan signifikansi pada Volcano Plot menunjukkan bahwa profil genetik ini merupakan representasi akurat dari patofisiologi kanker kepala dan leher. Temuan ini memberikan landasan untuk penelitian lebih lanjut dalam identifikasi target terapi spesifik bagi pasien HNSCC.

Daftar Pustaka (Contoh):

- GEO NCBI. Dataset GSE6631. (https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE6631).
- Ritchie, M.E., dkk. 2015. limma powers differential expression analyses for RNA-sequencing and microarray studies. Nucleic Acids Research.

Lampiran

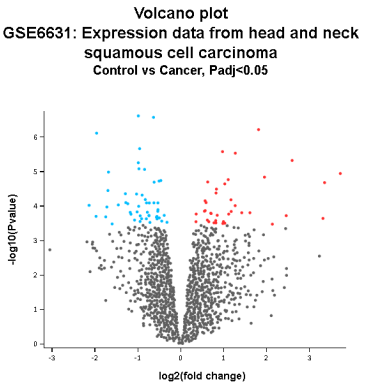
Volcano plot
GSE6631: Expression data from head and neck squamous cell carcinoma
Control vs Cancer, Padj<0.05
-log10(Pvalue)
log2(fold change)

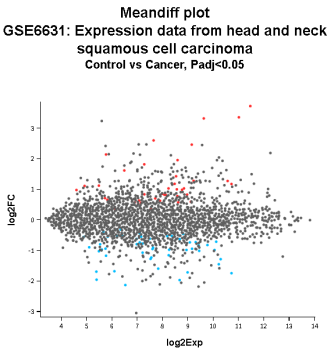
Meandiff plot
GSE6631: Expression data from head and neck squamous cell carcinoma
Control vs Cancer, Padj<0.05
log2FC
log2Exp

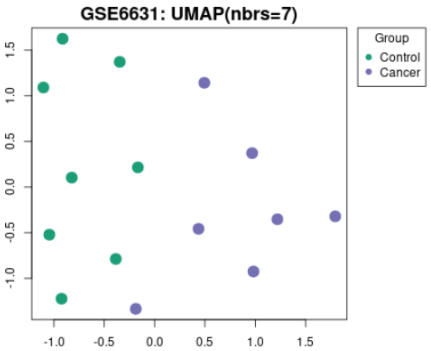
GSE6631: UMAP(nbrs=7)
Group
Control
Cancer

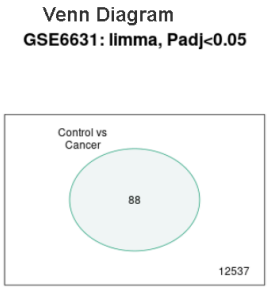
Venn Diagram
GSE6631: limma, Padj<0.05
Control vs Cancer
88
12537

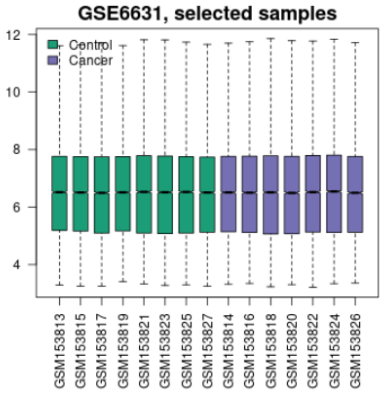
GSE6631, selected samples
Control
Cancer
GSM153813
GSM153815
GSM153817
GSM153819
GSM153821
GSM153823
GSM153825
GSM153827
GSM153814
GSM153816
GSM153818
GSM153820
GSM153822
GSM153824
GSM153826

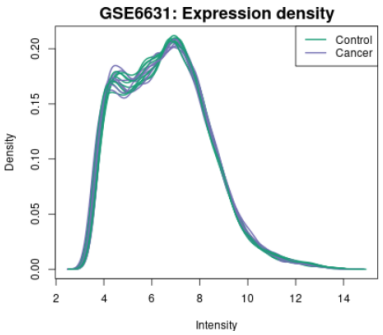
GSE6631: Expression density
Control
Cancer
Density
Intensity

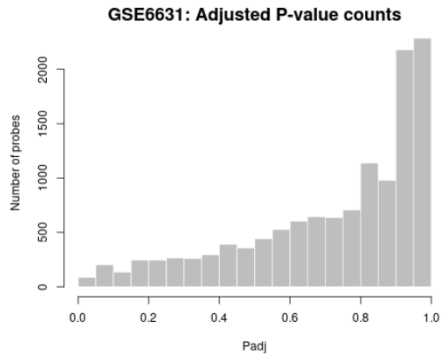

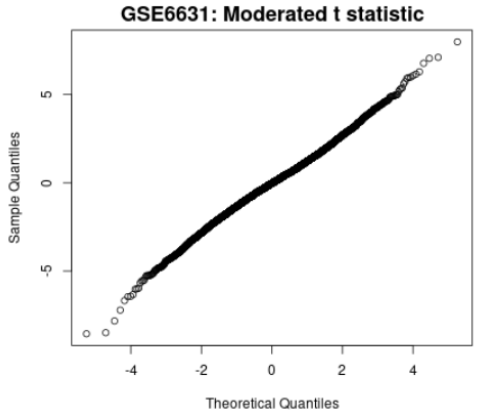

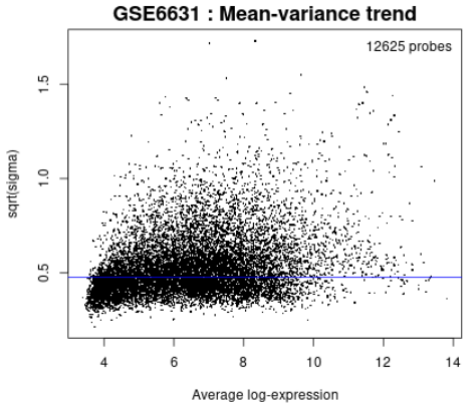


```
if (!require("BiocManager", quietly = TRUE)) install.packages("BiocManager")
BiocManager::install(c("limma", "GEOquery", "ggplot2", "ggrepel", "umap",
"RColorBrewer"))

library(GEOquery)
library(limma)
library(ggplot2)
library(ggrepel)
library(umap)

# 1. Load Data dari GEO
gse <- getGEO("GSE6631", destdir = ".", getGPL = TRUE)
exprs_data <- exprs(gse[[1]])
pdata <- pData(gse[[1]])

# Filter hanya untuk sampel yang Anda gunakan (15 sampel)
# Sesuaikan mapping GSM dengan Group (Control vs Cancer)
selected_samples <- c("GSM153813", "GSM153815", "GSM153817", "GSM153819",
                      "GSM153821", "GSM153823", "GSM153825", "GSM153827",
                      "GSM153814", "GSM153816", "GSM153818", "GSM153820",
                      "GSM153822", "GSM153824", "GSM153826")
exprs_data <- exprs_data[, selected_samples]
```

```
group <- factor(c(rep("Control", 8), rep("Cancer", 7)))

# 2. Normalisasi & Quality Control Plots
# Boxplot
boxplot(exprs_data, col = rep(c("#1B9E77", "#7570B3"), c(8, 7)),
       main = "GSE6631: Selected Samples", las = 2)

# Density Plot
plotDensities(exprs_data, group = group, col = c("#1B9E77", "#7570B3"),
            main = "GSE6631: Expression Density", legend = "topright")

# 3. UMAP Plot
dim_reduction <- umap(t(exprs_data))
plot_data <- data.frame(U1 = dim_reduction$layout[,1],
                        U2 = dim_reduction$layout[,2],
                        Group = group)
ggplot(plot_data, aes(U1, U2, color = Group)) +
  geom_point(size = 4) + theme_bw() +
  scale_color_manual(values = c("Control"="#1B9E77", "Cancer"="#7570B3")) +
  ggtitle("GSE6631: UMAP(nbrs=7)")

# 4. Linear Modeling (limma)
design <- model.matrix(~group)
fit <- lmFit(exprs_data, design)
fit <- eBayes(fit)
toptable <- topTable(fit, coef = 2, number = Inf)

# 5. Volcano Plot
toptable$diffexpressed <- "No"
toptable$diffexpressed[toptable$logFC > 0 & toptable$adj.P.Val < 0.05] <- "Up"
toptable$diffexpressed[toptable$logFC < 0 & toptable$adj.P.Val < 0.05] <- "Down"

ggplot(toptable, aes(x = logFC, y = -log10(P.Value), col = diffexpressed)) +
  geom_point() + theme_minimal() +
  scale_color_manual(values = c("Down"="#00BFFF", "No"="#808080", "Up"="#FF4500"))
+
  labs(title = "Volcano Plot GSE6631", subtitle = "Control vs Cancer, Padj < 0.05")

# 6. MA Plot (Meandiff Plot)
plotMA(fit, coef = 2, main = "Meandiff Plot GSE6631")

# 7. Histogram P-Value
hist(toptable$adj.P.Val, col = "grey", border = "white",
     xlab = "Padj", main = "GSE6631: Adjusted P-value counts")
```

```
# 8. QQ-Plot (Moderated t-statistic)
qqt(fit$t[,2], df = fit$df.prior + fit$df.residual, main = "GSE6631: Moderated t statistic")
abline(0, 1, col = "red")

# Contoh singkat untuk GO Enrichment
# Pastikan Anda sudah memiliki daftar GENE_SYMBOL
BiocManager::install("clusterProfiler")
library(clusterProfiler)
library(org.Hs.eg.db)

sig_genes <- rownames(toptable[toptable$adj.P.Val < 0.05, ])

go_result <- enrichGO(gene = sig_genes,
                      OrgDb = org.Hs.eg.db,
                      keyType = "PROBEID", # Sesuaikan dengan format ID data Anda
                      ont = "BP")
dotplot(go_result)

# Instal library anotasi untuk chip Affymetrix U95A
if (!require("hgu95av2.db", quietly = TRUE)) BiocManager::install("hgu95av2.db")
library(hgu95av2.db)

# 1. Ambil mapping antara Probe ID dan Gene Symbol
probe_ids <- rownames(toptable)
symbols <- mapIds(hgu95av2.db, keys = probe_ids, column = "SYMBOL", keytype =
"PROBEID", multiVals = "first")
entrez <- mapIds(hgu95av2.db, keys = probe_ids, column = "ENTREZID", keytype =
"PROBEID", multiVals = "first")

# 2. Masukkan ke dalam toptable
toptable$Symbol <- symbols
toptable$EntrezID <- entrez

# 3. Tampilkan 10 gen teratas yang paling signifikan
head(toptable[order(toptable$adj.P.Val), c("Symbol", "logFC", "adj.P.Val")], 10)

# Pilih 10 gen dengan p-value terkecil untuk diberi label
top_hits <- toptable[order(toptable$adj.P.Val), ] [1:10, ]

ggplot(toptable, aes(x = logFC, y = -log10(P.Value), col = diffexpressed)) +
  geom_point(alpha = 0.4) +
  geom_text_repel(data = top_hits, aes(label = Symbol), size = 5, box.padding = 0.5) +
```

```
  scale_color_manual(values = c("Down"="#00BFFF", "No"="#808080", "Up"="#FF4500"))
+
  theme_minimal() +
  labs(title = "Volcano Plot with Gene Labels", x = "log2 Fold Change", y = "-log10 P-Value")
library(clusterProfiler)

# Ambil hanya gen yang signifikan (Padj < 0.05)
sig_genes_entrez <- toptable$EntrezID[toptable$adj.P.Val < 0.05]
sig_genes_entrez <- na.omit(sig_genes_entrez) # Hapus yang tidak ter-mapping

# Jalankan Enrichment KEGG
kegg_res <- enrichKEGG(gene = sig_genes_entrez, organism = 'hsa')

# Visualisasi Jalur Teratas
dotplot(kegg_res, showCategory = 15) + ggtitle("KEGG Pathway Enrichment")
```